



ABIERTO

Clasificación de la carga cognitiva de tareas de interacción humano-computadora en realidad mixta basada en señales de sensores multimodales.

Yukang Hou, Qingsheng Xie, Ning Zhang y Jian Lv

La evaluación de la carga cognitiva en realidad mixta (RM) se ha convertido en un desafío importante en la interacción persona-ordenador (IPC). Para abordarlo, establecimos una plataforma experimental multimodal de RM con tres entornos distintos para inducir diferentes niveles de carga cognitiva. Los participantes realizaron tareas de interacción con máquinas herramienta CNC basadas en RM dentro de estos entornos. Utilizando los sensores integrados del casco de realidad mixta HoloLens 2 (HMD-RM) y sensores de frecuencia cardíaca portátiles, recopilamos datos fisiológicos y del dispositivo de los participantes mientras realizaban estas tareas. La carga cognitiva de los participantes se evaluó mediante el cuestionario NASA-TLX.

Los resultados experimentales indicaron que el tiempo de operación requerido en el entorno de realidad mixta aumentó un 49 % bajo una carga cognitiva alta en comparación con condiciones de baja carga. Los entornos de alta carga también provocaron mayor ansiedad, frustración y un menor rendimiento entre los participantes. Mediante experimentos comparativos, identificamos flujos de datos de sensores y algoritmos adecuados para la clasificación de la carga cognitiva y diseñamos un prototipo de sistema de alerta de carga cognitiva para una fábrica de gemelos digitales de realidad mixta. Este sistema utiliza un algoritmo Transformer-CL mejorado, logrando una precisión de clasificación de carga cognitiva del 95,83 %.

El sistema proporciona advertencias sobre la alta carga cognitiva, reduciendo los riesgos asociados con las tareas que requieren una alta carga cognitiva en entornos de trabajo de realidad mixta.

Palabras clave: Interacción persona-ordenador, Realidad mixta, Carga cognitiva, Seguimiento ocular, Sensor

La industria manufacturera está evolucionando rápidamente hacia sectores de alta tecnología. Dentro del sistema hombre-máquina-fabricación de la fábrica inteligente, los investigadores han desarrollado nuevas perspectivas sobre la relación entre el ser humano y la máquina en la producción industrial. Con los avances en la tecnología de automatización, muchas tareas repetitivas que antes requerían intervención humana han sido reemplazadas por máquinas. En consecuencia, el rol de los trabajadores en el proceso de fabricación está evolucionando. Los trabajadores ya no están limitados a la línea de montaje; ahora asumen roles como diseñadores, operadores y supervisores de máquinas. En la trayectoria tecnológica más reciente de la Industria 5.0, el enfoque de la fabricación ha pasado de sistemas orientados a sistemas orientados al ser humano, haciendo hincapié en la fabricación centrada en el ser humano¹. La cooperación colaborativa entre humanos y máquinas puede mejorar la eficiencia de la fabricación, mientras que la falta de coordinación entre ellos puede provocar pérdidas económicas y lesiones a los trabajadores².

Las máquinas industriales presentan diversos peligros y pueden provocar fácilmente accidentes de seguridad en el lugar de trabajo³. En 2022, la Oficina de Estadísticas Laborales de EE. UU. (BLS) reportó 738 muertes en Estados Unidos por contacto con objetos y equipos, de las cuales 199 fueron causadas por accidentes con maquinaria. De manera similar, datos del Ministerio de Gestión de Emergencias de la República Popular China muestran que en 2023 se registraron 310 accidentes de seguridad en la producción en la industria de maquinaria china, con un saldo de 294 fallecidos. Las lesiones mecánicas fueron la causa principal de estos accidentes. Los cinco sectores manufactureros con mayor número de accidentes de seguridad fueron productos metálicos, fabricación de equipos especiales, fabricación de equipos generales, reparación de maquinaria y equipos, y fabricación de automóviles, que en conjunto representaron más del 80 % del total de accidentes en la industria de maquinaria.

La adopción de tecnologías innovadoras en la producción industrial puede mejorar significativamente tanto la eficiencia como la seguridad. Cuando los trabajadores operan equipos industriales, el manejo oportuno de las alarmas de las máquinas es crucial para mantener la eficiencia de la línea de producción. Tradicionalmente, los equipos mecánicos alertan a los trabajadores a través de indicadores, pantallas, luces y sonidos de alarma. Estas tareas de mantenimiento a menudo requieren que los trabajadores se acerquen a áreas peligrosas para realizar inspecciones de seguridad. Este método aumenta el riesgo de lesiones. Sin embargo, la llegada de la tecnología de realidad mixta permite que la información de alarma virtual de los equipos mecánicos se integre sin problemas con los dispositivos del mundo real.

Laboratorio Clave de Tecnología de Fabricación Avanzada del Ministerio de Educación, Universidad de Guizhou, Guiyang 550025, China. Correo electrónico: jlv@gzu.edu.cn

Mediante el uso de auriculares de realidad mixta, el trabajador puede localizar rápidamente los equipos defectuosos y leerlos y mantenerlos de forma remota, lejos de las zonas peligrosas, reduciendo así los riesgos asociados al mantenimiento de los equipos.

En los procesos tradicionales de colaboración humano-máquina, la interacción entre humanos y máquinas se produce a través de componentes físicos como botones mecánicos, joysticks y diales. Los trabajadores reciben información de la máquina y del entorno mediante los sentidos visual, auditivo y táctil. Posteriormente, sus cerebros analizan, evalúan y toman decisiones, lo que da lugar a respuestas a la máquina. A medida que avanzan los terminales de HCI, los canales para el intercambio de información entre humanos y máquinas están experimentando cambios profundos. Los modos de interacción tradicionales basados en botones físicos son insuficientes para satisfacer las demandas de la HCI natural en los entornos modernos. En la era de la computación de realidad mixta, los dispositivos de interacción impulsados por sensores pueden integrar eficazmente la información virtual y física al reconocer e interpretar el entorno.

Sin embargo, en el entorno de fabricación potenciado por las nuevas tecnologías, el personal de mantenimiento que utiliza sistemas avanzados hombre-máquina y lleva un casco de realidad mixta (MR-HMD) puede enfrentarse a una mayor carga cognitiva. Esta carga cognitiva puede ser consecuencia de la interferencia de la información ambiental circundante o del impacto de la gran cantidad de interfaces virtuales y alarmas sonoras que muestran los dispositivos de realidad mixta. Dado que los entornos de trabajo industriales suelen contener niveles de ruido significativos, el cambio constante entre entornos virtuales y reales puede provocar efectos de cambio de atención, y la sobrecarga cognitiva de la memoria de trabajo al procesar más información puede resultar en una mayor carga cognitiva. La interferencia de información adicional también puede causar sobrecarga de información en los operadores, interrumpiendo la atención y perjudicando las capacidades cognitivas generales, lo que los somete a una carga cognitiva significativa. Por lo tanto, es esencial estudiar la carga cognitiva que experimentan los trabajadores que llevan un casco de realidad mixta mientras realizan tareas en entornos ruidosos.

Actualmente, se han realizado investigaciones sobre la carga cognitiva en paneles de datos⁹. Realidad Virtual (RV)¹⁰ y Realidad Aumentada (RA)¹¹. Sin embargo, la investigación sobre la detección de carga cognitiva mediante realidad mixta (RM) en entornos industriales sigue siendo limitada. El objetivo principal de esta investigación es clasificar la carga cognitiva en tareas de HCI multimodales en un entorno de gemelo digital industrial. En nuestro estudio, planteamos la hipótesis de que la carga cognitiva de los usuarios puede medirse a través de los datos y las respuestas fisiológicas recopiladas de los dispositivos RM-HMD. Específicamente, proponemos que los datos de dinámica de la cabeza, los datos de movimiento ocular y los diversos datos de movimiento de las manos de los participantes contienen información oculta relacionada con la carga cognitiva. Esta información puede reflejar la interferencia del entorno de carga en el rendimiento de la tarea de los participantes. Para probar esta hipótesis, diseñamos y realizamos una serie de experimentos relevantes.

Las contribuciones de este artículo son las siguientes:

1. Mediante el uso de una máquina CNC gemela digital, un casco de realidad virtual para resonancia magnética (MR-HMD) y sensores de frecuencia cardíaca portátiles, este estudio estableció una plataforma experimental para tareas de carga cognitiva que implican el funcionamiento de una máquina CNC en un entorno de resonancia magnética. Diseñamos tres variables de entornos de carga cognitiva dentro del entorno de tareas de interacción humano-computadora (HCI) de resonancia magnética.
2. Mediante los sensores integrados del casco de realidad virtual con resonancia magnética (MR-HMD) y los sensores de frecuencia cardíaca, recopilamos datos de movimiento de la cabeza, seguimiento ocular, articulaciones de las manos y frecuencia cardíaca de 20 participantes durante un total de 120 tareas de interacción en tres entornos de carga cognitiva diferentes. Estos datos se compilaron en un conjunto de datos completo.
3. El tiempo de finalización de la tarea es un parámetro crucial para evaluar el rendimiento. Al realizar tareas de interacción en entornos de realidad mixta, registramos los tiempos de finalización y observamos que el tiempo de finalización era un 49 % mayor en entornos de alta carga en comparación con entornos de baja carga. Además, aplicamos el cuestionario NA-SA-TLX para evaluar la carga cognitiva de los participantes en tres entornos de carga diferentes. El cuestionario incluía seis dimensiones: demanda mental, demanda física, demanda temporal, rendimiento, esfuerzo y frustración. Esto nos permitió obtener las percepciones cognitivas y los estados mentales de los participantes bajo diferentes condiciones de carga.

Tras comparar diversos algoritmos, identificamos el más adecuado para la clasificación de la carga cognitiva a partir de los datos de los sensores MR-HMD. Finalmente, utilizamos una red Transformer-CL mejorada para la clasificación de la carga cognitiva, que alcanzó una precisión del 95,83 %. Asimismo, diseñamos un prototipo de sistema de alerta de carga cognitiva que avisa a los trabajadores con alta carga cognitiva en entornos de trabajo con realidad mixta, mitigando así los riesgos asociados a dichas operaciones.

Las demás secciones de este artículo se organizan de la siguiente manera: La sección de Revisión ofrece una visión general de los trabajos relacionados con la interacción persona-ordenador basada en realidad mixta (MR HCI) y la carga cognitiva. La sección de Experimento describe nuestro diseño experimental y la configuración de la plataforma experimental. La sección de Procesamiento y Análisis de Datos presenta un análisis de los resultados experimentales y aplica diversos modelos de clasificación a los datos de los sensores. La sección de Discusión y Limitaciones analiza los resultados del experimento y examina las limitaciones del método propuesto. La sección de Conclusiones resume los hallazgos clave del estudio y describe posibles líneas de investigación futuras.

Revisar

Investigación sobre MR-HCI

La realidad virtual (RV), la realidad aumentada (RA) y la realidad mixta (RM) son terminales de información de interacción persona-ordenador (HCI) de última generación que evolucionan rápidamente, con un creciente número de investigaciones en estas áreas. Existen ciertas diferencias en los enfoques tecnológicos de la RV, la RA y la RM: la RV sumerge a los usuarios en un entorno virtual generado por ordenador; la RA superpone información virtual al mundo físico; la RM, un avance de la tecnología de RA, enfatiza aún más la percepción del entorno y la fusión de información virtual y real, reduciendo así la brecha entre el mundo físico y la información virtual.

Entre los dispositivos de realidad mixta más comunes se encuentran Magic Leap, Microsoft HoloLens y Apple Vision Pro. Estos dispositivos integran información virtual con el mundo físico mediante tecnologías como sensores de tiempo de vuelo (TOF), giroscopios y modelado espacial para percibir y comprender el entorno.

La RM se aplica ampliamente en campos como la educación^{12,13}, la atención médica¹⁴, la música¹⁵, la fabricación¹⁶, la colaboración hombre-máquina¹⁷, etc. En la fabricación, la RM puede contribuir a un diseño, desarrollo y producción más eficientes.

validación¹⁸ y promover la fabricación inteligente de fábricas¹⁹. Debido a la aparición más temprana de la tecnología VR/AR, hay más investigación y aplicaciones prácticas relacionadas con VR/AR que con MR. Dado que tanto VR/AR como MR requieren el uso de HMD para funcionar, los resultados de la investigación relacionada pueden servir como referencias para estudiar la carga cognitiva en MR.

Algunos investigadores sugieren que la aplicación de la tecnología AR puede reducir la carga cognitiva.

Por ejemplo, la aplicación de la tecnología de RA en tareas de ensamblaje en la fabricación puede permitir a los operarios realizar tareas más complejas y reducir los niveles de estrés²⁰. Los estudiantes que aprenden a través de RA tienen un mayor rendimiento académico y una menor carga cognitiva²¹, y la lectura de libros de RA también impone una menor carga cognitiva²². Sin embargo, algunos investigadores han descubierto que, si bien los entornos de RV pueden proporcionar una sensación de inmersión, también pueden provocar sobrecarga cognitiva y dispersión de la atención entre los estudiantes, lo que en última instancia afecta a los resultados del aprendizaje²³. Por lo tanto, existen algunas discrepancias con respecto a la magnitud de la carga cognitiva en entornos de RV y RA, que pueden deberse a diferencias en la complejidad de las tareas o estar relacionadas con los sistemas de información y las interfaces HCI.

Con el desarrollo de las interfaces gráficas de computadora y la tecnología HCI, los sistemas de información se han convertido en el puente principal para HCI. La carga cognitiva impacta significativamente cómo las personas usan los sistemas de información²⁴. Por ejemplo, la investigación ha encontrado que el desempeño de las tareas de HCI está relacionado con el entorno de interacción del usuario y la interfaz gráfica de usuario (GUI); cuantos más elementos en la interfaz, mayor es la carga cognitiva para el usuario²⁵. Cuando la carga cognitiva de información adicional es alta, consume la mayor parte de los recursos atencionales de un individuo, lo que resulta en pocos o ningún recurso disponible para procesar información irrelevante para la tarea²⁶. Reducir la carga cognitiva innecesaria durante la ejecución de tareas es una dirección importante para la investigación de la experiencia del usuario y para prevenir riesgos de seguridad en la producción causados por distracciones y sobrecarga cognitiva.

Carga cognitiva

La Teoría de la Carga Cognitiva²⁷ se aplicó inicialmente en el campo de la educación, estudiando principalmente cómo lograr procesos de aprendizaje eficientes dentro de las limitaciones de la capacidad cognitiva y de memoria humanas. La carga cognitiva durante el proceso de aprendizaje surge debido a la capacidad y duración limitadas de la memoria de trabajo, causadas principalmente por las demandas cognitivas en las tareas y entornos de aprendizaje²⁸. Si existen interferencias cognitivas sustanciales y prolongadas, esto conduce a una disminución en la velocidad de procesamiento cognitivo. Por lo tanto, es necesario gestionar la carga cognitiva. La sobrecarga cognitiva ocurre cuando la cantidad de recursos cognitivos requeridos para realizar una tarea excede los recursos cognitivos disponibles, lo que resulta en una degradación severa del rendimiento y la seguridad²⁹. Analizar y predecir la carga cognitiva puede alertar oportunamente a los trabajadores sobre los riesgos cognitivos actuales, garantizando la seguridad de los trabajadores que operan en entornos de alta carga.

La investigación sobre la carga cognitiva requiere inducir a los participantes a experimentarla. Actualmente, los principales métodos de inducción incluyen la inducción de carga psicológica basada en la tarea dual N-Back³⁰, a través de tareas de generación de verbos³¹, mediante imágenes emocionales³² y mediante la inducción de estímulos visuales, táctiles y auditivos³³, entre otros. La estimulación auditiva es un factor significativo que afecta la carga cognitiva. En entornos industriales, el ruido es inevitable y los trabajadores en el sitio a menudo están expuestos a él³⁴. La investigación existente indica que el ruido de fondo en el entorno se considera un factor estresante y se ha demostrado que impacta negativamente el desempeño cognitivo de las personas en tareas como la atención, la memoria y la toma de decisiones³⁵. El ruido afecta las neuronas de atención³⁶ e influye en las funciones ejecutivas²⁶ y la comprensión lectora³⁷. El ruido conduce a una reducción en la capacidad de reserva cognitiva, que está relacionada con las diferencias individuales en la capacidad de memoria de trabajo³⁸. Particularmente en tareas cognitivas complejas, el impacto de los niveles de ruido se vuelve más significativo. Si bien los niveles de ruido no afectan significativamente los tiempos de respuesta en tareas de atención, sí los afectan en tareas de memoria a corto plazo³⁹.

La medición de la carga cognitiva implica principalmente dos métodos: la medición subjetiva y la medición objetiva. La medición subjetiva se realiza principalmente mediante autoinformes a través del llenado de cuestionarios. Los métodos comunes incluyen el Índice de Carga de Trabajo de la NASA (NASA-TLX) y su versión optimizada⁴⁰, la Técnica de Evaluación Subjetiva de la Carga de Trabajo (SWAT)⁴¹, el Cuestionario de Recursos Múltiples (MRQ)⁴² y la escala modificada de Cooper-Harper (MCH)⁴³. Los métodos de medición objetiva implican sensores biométricos no invasivos para recopilar señales fisiológicas para medir la carga cognitiva⁴⁴. La investigación existente muestra una relación significativa entre la carga cognitiva y las señales fisiológicas⁴⁵. Las demandas de tareas más altas generalmente conducen a una mayor dilatación pupilar en dominios de control cognitivo como la actualización, el cambio y la inhibición⁴⁶. Los métodos específicos de medición de la carga cognitiva incluyen la evaluación de la duración de la mirada, el tiempo de fijación y los cambios en el diámetro pupilar a través del seguimiento ocular⁴⁷, o la evaluación de acoplamiento entre el diámetro pupilar y la frecuencia cardíaca (FC)⁴⁸. Otros métodos implican el uso de redes de memoria a corto y largo plazo (LSTM)⁴⁹, redes Bi-LSTM⁵⁰, redes neuronales recurrentes (RNN)⁵¹ para clasificar y predecir la carga cognitiva en función de las señales de electroencefalograma (EEG), o la calificación de la carga cognitiva en el control del tráfico aéreo en función de las características del habla⁵². Además, la carga cognitiva se puede estudiar a través de las respuestas neurovasculares y el rendimiento en la tarea⁵³.

Actualmente, la evaluación de la carga cognitiva en entornos de RM suele realizarse mediante cuestionarios.⁵⁴ Algunos investigadores han intentado evaluar la carga cognitiva en entornos de RM utilizando métodos fisiológicos.⁵⁵ Sin embargo, los métodos existentes no utilizan los sensores integrados del HMD de RM, sino que se basan en proyecciones en pantalla y sensores externos de seguimiento ocular para las mediciones. Este enfoque aumenta la complejidad del proceso de medición e introduce posibles interferencias en los datos. Para evaluar con mayor precisión la carga cognitiva de las tareas de HCI en RM, realizamos experimentos de interacción cognitiva en RM con un grupo de participantes. Recopilamos señales fisiológicas utilizando los sensores integrados del HMD de RM y pulseras de frecuencia cardíaca, y empleamos diversos algoritmos para clasificar los datos de carga cognitiva. Durante los experimentos, registramos los tiempos de finalización de las tareas y pedimos a los participantes que evaluaran su carga cognitiva utilizando la escala NASA-TLX. Finalmente, desarrollamos un sistema de alerta de carga cognitiva para garantizar la seguridad del personal.

Experimento

Reclutamos participantes para realizar una tarea de mecanizado CNC mientras usaban un casco de realidad mixta (MR-HMD) bajo tres entornos de carga cognitiva diferentes. Esta sección proporciona una descripción detallada de la selección de participantes, la

La configuración y el entorno experimental, el diseño de los entornos de inducción de carga cognitiva y los procedimientos específicos seguidos durante la ejecución de la tarea.

Participantes experimentales

Se reclutaron un total de 20 participantes (15 hombres y 5 mujeres) para este experimento, con una estatura promedio de 172,1 centímetros (desviación estándar, DE=8,59) y una edad promedio de 25,1 años (DE=2,14). Todos los participantes tenían un título universitario o un nivel de estudios superiores. Los participantes tenían experiencia en el uso de máquinas herramienta CNC y estaban familiarizados con sus procedimientos operativos básicos. Durante el experimento, cada participante tenía visión normal o corregida a la normalidad, gozaba de buena salud física sin lesiones en las extremidades, enfermedades ni hábitos perjudiciales, y superó la prueba de daltonismo. En las 48 horas previas al experimento, los participantes no realizaron actividades extenuantes, no recibieron medicamentos ni consumieron bebidas que contuvieran cafeína, té, taurina, etc., que pudieran afectar los datos experimentales, y se aseguraron de dormir lo suficiente. Además, no se observaron extremos en la autoevaluación de la personalidad y su sensibilidad al estrés era normal.

Equipos y entorno experimentales

El experimento se llevó a cabo en el Laboratorio de Líneas de Producción de Gemelos Digitales de la Universidad de Guizhou, que cuenta con equipos de líneas de producción de gemelos digitales, incluyendo máquinas herramienta CNC, brazos robóticos, cintas transportadoras, máquinas de grabado y más. La arquitectura general del entorno experimental se muestra en la Figura 1.

Para mitigar los posibles riesgos derivados del funcionamiento de los equipos mecánicos, los participantes permanecieron estrictamente confinados en zonas seguras, alejadas de la maquinaria, durante los experimentos de interacción persona-ordenador. Para evitar molestias en la cabeza, fatiga ocular y fatiga en las manos por el uso prolongado del casco de realidad virtual, la duración de cada sesión se limitó a un máximo de 10 minutos. Además, para evitar daños auditivos por un entorno ruidoso, el nivel máximo de ruido durante el experimento de realidad virtual se controló para que no superara los 90 decibelios, garantizando así que no supusiera un riesgo para la salud auditiva de los participantes.

La plataforma experimental incluye los siguientes dispositivos de hardware: Microsoft HoloLens 2, router Wi-Fi Honor ws851, ordenador portátil y pulsera de frecuencia cardíaca Huawei GT3. El entorno interactivo de realidad mixta para el experimento se desarrolló con Unity 2021.3.23f1c1. Las HoloLens 2 están equipadas con dos cámaras infrarrojas, cada una con 12 LED infrarrojos, situadas en el puente nasal. Esta configuración utiliza un sistema de seguimiento ocular por reflexión corneal con iluminación LED infrarroja para capturar información de seguimiento ocular en tiempo real. La pulsera GT3 emplea un sensor fotoeléctrico para recopilar datos de frecuencia cardíaca y utiliza la transmisión Bluetooth para transmitir dicha información en tiempo real.

Para capturar datos en tiempo real durante el experimento de RM, activamos el modo de investigación de HoloLens 2 para que el programa experimental tuviera acceso a sus sensores integrados. La recopilación y transmisión de los datos de los sensores del HMD de RM se integraron en Unity mediante el programa HL2SS modificado. Los datos se transmiten mediante transmisión TCP. Se utilizó un ordenador portátil como host receptor de datos para recopilar y registrar los datos de los sensores.

Procedimiento experimental

Este experimento recibió la aprobación del Comité de Ética de la Universidad de Guizhou (número de aprobación HMEZ-GZU-2023-TO25). Para este experimento, todos los participantes debían leer y firmar el formulario de consentimiento informado al inicio para comprender el proceso y los términos del experimento. Antes del experimento, los participantes recibieron capacitación para operar la máquina herramienta CNC en realidad mixta (RM) y completar tareas interactivas. La capacitación incluyó tutoriales en video e instrucciones verbales. Antes del experimento formal, los participantes realizaron experimentos interactivos simulados frente a la interfaz real de la máquina herramienta CNC sin el casco de realidad mixta (HMD). Posteriormente, una vez familiarizados con el funcionamiento, se pusieron el HMD para realizar una operación previa al experimento en la interfaz virtual de la máquina herramienta CNC, lo que garantizó que cada participante estuviera familiarizado con todo el proceso de las tareas interactivas de la máquina herramienta CNC en este experimento de RM.

Al inicio del experimento, los participantes se sentaron en una silla fija ubicada a 40 cm fuera de la zona de seguridad de la línea de producción, con una altura de asiento de 45 cm. Primero, se les indicó que se pusieran la pulsera de frecuencia cardíaca, ajustándola a un dedo de distancia de la muñeca para asegurar una presión moderada, lo que permitiría al dispositivo capturar con precisión la información de la frecuencia cardíaca en tiempo real. A continuación, se conectó el Bluetooth.




Figura 1. Arquitectura del sistema del entorno experimental de resonancia magnética.




Figura 2. Entorno experimental, lugar y dispositivo de grabación: (a) un participante que lleva un HoloLens para participar en el experimento, (b) la interfaz gráfica de usuario experimental diseñada en Unity, (c) la pantalla de realidad mixta que se muestra en el HoloLens, (d) el host utilizado para recopilar y grabar datos.

Carga ambiental	Carga cognitiva inducida estimulación	MR-HMD Volumen
A	Estimulación auditiva: Ruido de ambiente de fábrica, alarma de máquina Estimulación visual: 10 ventanas de alarma de RM que aparecen en la máquina.	70%
B	Estimulación auditiva: Ruido de ambiente de fábrica, alarma de máquina Estimulación visual: 1 ventana de alarma de RM que aparece en la máquina.	40%
do Grupo de control	Estimulación auditiva: Sonido de fondo normal de un entorno de fábrica tranquilo. Estimulación visual: ninguna	10%

Tabla 1. Estimulación inducida por carga cognitiva y volumen de MR-HMD en diferentes entornos experimentales.

Se activó la función de transmisión de la pulsera. Finalmente, se colocó el casco de realidad virtual (MR-HMD). Antes de que cada participante comenzara el experimento con el dispositivo, fue necesario recalibrar el sistema de seguimiento ocular para garantizar la precisión de los datos. El lugar y el entorno experimental se muestran en la figura 2.

Estimulación experimental

En entornos industriales, la gestión y el control de la carga cognitiva son fundamentales. Por ejemplo, en entornos laborales complejos y de alta presión, como centrales nucleares, aviación y manufactura, los operarios deben tomar decisiones rápidas y precisas durante el funcionamiento de equipos complejos y en situaciones de emergencia. Una carga cognitiva excesiva puede provocar errores en la toma de decisiones, retrasos en las reacciones o fatiga, lo que aumenta los riesgos para la seguridad. El ruido se considera a menudo una dimensión importante de la carga cognitiva ambiental. El ruido industrial, al ser una de las fuentes de ruido más importantes, puede afectar gravemente el sistema auditivo de los trabajadores⁵⁷, interrumpir la atención y perjudicar el rendimiento en tareas cognitivas⁵⁸. Cuando los equipos industriales fallan o presentan anomalías, los sistemas de alarma suelen alertar a los operadores mediante ventanas emergentes o señales sonoras, lo que exige respuestas y toma de decisiones rápidas. La exposición prolongada a los sonidos de alarma puede provocar una sobrecarga cognitiva, contribuyendo a la fatiga por alarmas y afectando negativamente el rendimiento en las tareas⁵⁹. Múltiples alarmas pueden indicar diversos problemas del sistema o requerir que los operadores se concentren en varias tareas simultáneamente, lo que complica aún más la asignación de recursos cognitivos. Inducir carga cognitiva mediante el volumen del sonido y el número de ventanas emergentes de alarma puede simular la intensidad de los estímulos de carga cognitiva que se encuentran en escenarios industriales reales, reflejando la asignación de recursos atencionales durante tareas específicas.

Para simular escenarios industriales reales en el entorno experimental, grabamos un segmento de audio de una fábrica real, que incluye los sonidos operativos de grandes equipos de estampado y el ruido generado por maquinaria típica. Además, se incorporaron alarmas emergentes y sonidos de equipos de maquinaria al entorno experimental para replicar los problemas de alarma que podrían encontrar los trabajadores. Diseñamos tres entornos de trabajo virtuales de carga cognitiva basados en MR, cada uno con ruido ambiental y señales de alarma: el Entorno de Carga Cognitiva A presenta un alto nivel de ruido ambiental y múltiples alarmas emergentes, simulando un escenario en el que los operadores deben abordar múltiples tareas urgentes en un entorno de fábrica complejo; el Entorno de Carga Cognitiva B incluye un nivel moderado de ruido ambiental y algunas alarmas emergentes, simulando una situación con una carga de trabajo moderada en la producción industrial; el Entorno de Carga Cognitiva C, que sirve como grupo de control, opera con bajo nivel de ruido ambiental y sin alarmas, simulando un entorno de trabajo normal. Los elementos de estímulo disruptivo y los volúmenes de equipo para cada entorno de carga se presentan en la Tabla 1. Durante el experimento, cada participante usó un HMD de MR y realizó tareas interactivas en los tres entornos de carga cognitiva. Los tres entornos se presentaron en orden aleatorio, repitiéndose cada escenario de carga dos veces, lo que dio como resultado un total de seis sesiones experimentales por participante.

Tareas del experimento

En el entorno experimental de realidad mixta (RM), simulamos la interfaz HCI de la plataforma de operación de la máquina herramienta CNC FANUC SERIES Oi-MF. Dado que la preparación de la máquina herramienta antes del mecanizado es crucial, realizamos la inspección del estado de la máquina herramienta como tarea experimental, es decir, desactivamos la parada de emergencia y ponemos a cero las coordenadas del husillo. Considerando que las operaciones de las máquinas herramienta tradicionales siguen procedimientos fijos y que los participantes deben utilizar sus conocimientos básicos de operación durante el experimento, no modificamos los iconos ni la lógica de interacción de la interfaz de operación de la máquina herramienta en la plataforma experimental de RM.

En la tarea, los participantes comenzaron haciendo clic en el icono para acceder al programa experimental de carga cognitiva, activando la interfaz HCI de la máquina herramienta CNC gemela digital. Tras el acceso inicial, debían hacer clic en el botón "Abrir socket" de la interfaz para establecer una conexión con el host de adquisición de datos remoto a través de un enrutador. Una vez que el host de adquisición de datos muestra "Conexión establecida correctamente", indica que la conexión se ha establecido. Una vez finalizada la preparación, el experimentador anuncia el inicio formal del experimento. Los pasos a seguir durante la tarea experimental y los comandos correspondientes del programa HCI se muestran en la figura 3.

- Paso 1: Haga clic en el botón "Encender". Después de que se cargue la interfaz de autocomprobación, la máquina herramienta CNC gemela digital en el MR se iniciará y mostrará la interfaz predeterminada.
- Paso 2: Haga clic en el botón "Mensaje" para comprobar la información de alarma actual de la máquina herramienta CNC.
- Paso 3: Después de verificar la información de la alarma, haga clic en el botón "Emergencia" para liberar la emergencia actual. estado de parada de emergencia después de comprobar la información de la alarma.
- Paso 4: Después de desactivar la alarma de emergencia, haga clic en el botón "POS" para abrir la interfaz que se muestra en la posición del husillo.
- Pasos 5-6: Haga clic en el botón "JOG" para abrir el modo de avance manual y, a continuación, haga clic en el botón "ZRN" para iniciar el modo de puesta a cero del eje.
- Pasos 8-10: En el modo ZRN, los participantes hacen clic secuencialmente en los botones "+X", "+Y", "+Z" y "+A" para regresar. los ejes X, Y, Z y A de la máquina herramienta al origen mecánico.
- Paso 11: Haga clic en el botón "PROG" para entrar en el modo de programación.
- Paso 12: Haga clic en el botón "Apagar" para enviar un mensaje de detención de la grabación al host en el paso anterior, lo que indica que el experimento ha finalizado. Al recibir el mensaje, el host guarda y muestra el flujo de datos del sensor de este experimento.

Los participantes debían usar el casco de realidad virtual (MR-HMD) y la pulsera de frecuencia cardíaca según las instrucciones. En el entorno de realidad virtual, completaron todas las tareas de interacción del paso 1 al paso 12. Los datos experimentales recopilados incluyeron 22 conjuntos de información, como la posición de la cabeza, el seguimiento ocular, el reconocimiento de gestos y la frecuencia cardíaca, con una frecuencia de muestreo uniforme de 30 Hz/s. Después de cada experimento, los participantes tuvieron un descanso de 5 minutos durante el cual completaron el cuestionario NASA-TLX. El NASA-TLX es una herramienta utilizada para la evaluación subjetiva de la carga cognitiva, que permite a los usuarios evaluar subjetivamente la carga cognitiva del sistema HCI60. El formulario consta de seis dimensiones: Demanda Mental, Demanda Física, Demanda Temporal, Rendimiento, Esfuerzo y Frustración. La escala se divide de 0 a 100 con 21 marcas verticales, cada una con incrementos de 5. El cuestionario se traduce al chino para facilitar su comprensión a todos los participantes durante la evaluación. Tras la evaluación, el siguiente experimento se realiza únicamente cuando la frecuencia cardíaca del participante ha vuelto a su nivel basal. El objetivo de este diseño es evitar que el proceso experimental continuo afecte a la precisión de los datos.




Figura 3. Pasos y comandos que deben ejecutarse durante la tarea experimental.

Procesamiento y análisis de datos

En la sección anterior, describimos la configuración y el procedimiento experimental, durante el cual se recopilaban datos de los sensores MR-HMD de los participantes. Al finalizar el experimento, se invitó a los participantes a completar el cuestionario NASA-TLX. En la siguiente sección, describimos los métodos de procesamiento y análisis de datos, así como la implementación de diversos modelos de clasificación de carga cognitiva basados en los datos de los sensores recopilados.

Niveles de ruido

Para evaluar con mayor precisión los datos de ruido reales en el entorno experimental, utilizamos el medidor de ruido UNI-T UT353 para medir los niveles de decibelios de los tres entornos experimentales durante la fase previa al experimento. Primero, colocamos el medidor debajo de la unidad emisora de sonido del casco de realidad virtual (MR-HMD), simulando la posición de la entrada del conducto auditivo del participante. A continuación, realizamos las tareas y medimos los niveles de sonido en los entornos experimentales A, B y C. Finalmente, se midieron los niveles de ruido en decibelios de cada entorno experimental, como se muestra en la Figura 4.

Resultados de NASA-TLX

Debido a que algunos estudios sugieren que calcular directamente la carga de trabajo general mediante la escala NASA-TLX tiene una significancia matemática limitada^{61,62}, utilizamos la escala NASA-TLX original de seis dimensiones para evaluar la carga de trabajo cognitiva. El análisis de las puntuaciones de la NASA-TLX de 20 participantes reveló las siguientes conclusiones, como se muestra en la Fig. 5.

En cuanto a la exigencia mental, los participantes percibieron el entorno de carga A como el más exigente, con una puntuación de 78,25. Esto indica que realizar tareas en dicho entorno requiere más recursos cognitivos y atención. La exigencia mental del entorno de carga B fue de 11, aunque menor, requirió cierto esfuerzo mental. El grupo de control C presentó la menor exigencia mental, con una puntuación de tan solo 29,75, lo que indica que un entorno de carga cognitiva con poco ruido y sin alarmas requiere menos esfuerzo mental.

En cuanto a la exigencia física, los participantes calificaron el entorno de carga A con un 57,5 y el entorno de carga B con un 49,25. Aunque la diferencia entre A y B fue pequeña, ambas puntuaciones fueron superiores a las del grupo de control C, que obtuvo 27,5. Esto sugiere que realizar tareas en los entornos A y B puede requerir un mayor esfuerzo físico.


En cuanto al tiempo requerido, los participantes calificaron el entorno de alta carga A con un 64, lo que indica el mayor tiempo requerido. El grupo de control C presentó el menor tiempo requerido, con una puntuación de tan solo 25,75. Esto concuerda con nuestra tendencia estadística de tiempos de finalización de tareas. El rendimiento en las tareas se correlacionó inversamente con los niveles de ruido: el grupo de control C obtuvo la puntuación de rendimiento más alta, de 88, mientras que el entorno de alta interferencia A obtuvo la puntuación de rendimiento más baja, de tan solo 33.

En cuanto al esfuerzo, los participantes consideraron que el entorno de carga A requería el mayor esfuerzo, con una puntuación de 75,5, mientras que el grupo de control C requería significativamente menos esfuerzo, con una puntuación de tan solo 29. El esfuerzo necesario en entornos de baja interferencia fue mucho menor que el requerido en entornos de alta interferencia.

En cuanto a la frustración en la tarea, el entorno de carga A indujo la mayor frustración entre los participantes, con una puntuación de 79, lo que indica peores estados emocionales en condiciones de alta interferencia. El grupo de control C obtuvo la puntuación de frustración más baja, de 20,25, mostrando una frustración significativamente menor que los otros dos entornos. Los comentarios de los participantes también revelaron que muchos informaron haber realizado más clics erróneos en el entorno de carga A con alto nivel de ruido, lo que coincide con hallazgos previos de experimentos realizados en entornos reales⁶³, que han demostrado que los entornos de alta carga aumentan la probabilidad de errores operativos humanos.

frecuencia cardíaca

La Figura 6 mostró el cambio promedio de frecuencia cardíaca de los participantes en todos los experimentos. La Tabla 2 presentó los cambios en la frecuencia cardíaca en todos los experimentos. Se puede observar que los cambios en las frecuencias cardíacas de los participantes son bastante similares bajo los tres entornos de carga, y las tasas de cambio también son menos diferentes antes y después de la tarea. Esto indica que el entorno experimental tiene un impacto mínimo en los cambios de frecuencia cardíaca. Realizamos un experimento de uno a uno.



Load Environment	Maximum dB(A)	Minimum dB(A)	Average dB(A)
A	87.4	73.5	80.86
B	77.4	66.3	72.48
C (Control Group)	65.4	44.7	49.54

Figura 4. Niveles de ruido en decibelios en cada entorno experimental, medidos por el instrumento.




Figura 5. Resultados de la medición de la carga cognitiva de la NASA-TLX.




Figura 6. Cambio promedio de la frecuencia cardíaca en todos los experimentos.

Carga ambiente	Inicial frecuencia cardíaca	Promedio frecuencia cardíaca	Final Frecuencia cardíaca	Cambio de frecuencia
A	80.925	83.825	85.575	+5,7%
B	79.275	82.175	83.825	+5,7%
do (Grupo de control)	76.975	79.7	81,85	+5,4%

Tabla 2. Cambios en la frecuencia cardíaca en todos los experimentos.

Análisis de varianza de dos vías sobre la frecuencia cardíaca promedio de los participantes durante la realización de la tarea en diferentes entornos de carga cognitiva. El valor F fue de 1,042 y el valor p de 0,356 (>0,05). Esto sugiere que el entorno de la tarea no tiene un efecto significativo en la frecuencia cardíaca promedio, lo cual concuerda con los resultados de los experimentos realizados en [VR45](#). Este resultado coincide con los hallazgos del experimento del algoritmo de clasificación de carga cognitiva presentados en la Tabla 3. Por lo tanto, no utilizamos los datos de frecuencia cardíaca para la clasificación en el prototipo final del sistema de alerta de carga cognitiva.

Tiempo de finalización de la tarea

El tiempo de finalización de la tarea es un parámetro crítico para evaluar el rendimiento de la misma. Para evaluar el rendimiento de la tarea en diferentes entornos de carga, recopilamos los tiempos de finalización de cada tarea experimental, como se ilustra en la figura 7.

Algoritmo	Conjunto de datos	Estructura de red	Tasa de precisión	Puntuación F1 AUC	
Transformador-CL	Movimiento de la cabeza	Entrada: (tamaño de la ventana, 6, 9, 21 o 22)	70,83%	0,71	0,78
	Seguimiento ocular	Codificador Transformer: (tamaño_cabeza:32, número_cabeza:4, dimensión_ff:64, caída:0,5)	79,10%	0,80	0,84
	Gestos con las manos	Agrupación promedio global1D	70,83%	0,70	0,80
	Movimiento de cabeza + Seguimiento ocular + Mano Gestos	Abandono escolar (0,5) Denso (64 unidades, activación Relu)	95,83%	0,96	0,99
	Movimiento de cabeza + Seguimiento ocular + Mano Gestos + Frecuencia cardíaca	Abandono escolar (0,5) Denso (3 unidades, activación Softmax)	83,33%	0,83	0,96
BiLSTM	Movimiento de la cabeza	Entrada: (tamaño de la ventana, 6, 9, 21 o 22)	69,44%	0,68	0,88
	Seguimiento ocular	BiLSTM: (16 unidades, secuencias de retorno=Verdadero)	63,89%	0,62	0,76
	Gestos con las manos	Abandono: (0,5) BiLSTM: (8 unidades, secuencias de retorno=Verdadero)	58,33%	0,56	0,77
	Movimiento de cabeza + Seguimiento ocular + Mano Gestos	Abandono: (0,5) BiLSTM: (16 unidades)	80,56%	0,81	0,89
	Movimiento de cabeza + Seguimiento ocular + Mano Gestos + Frecuencia cardíaca	Abandono: (0,5) Denso: (64 unidades, activación Relu) Denso: (3 unidades, activación Softmax)	77,78%	0,78	0,83
LSTM	Movimiento de la cabeza	Entrada: (tamaño de la ventana, 6, 9, 21 o 22)	62,50%	0,63	0,80
	Seguimiento ocular	LSTM: (100 unidades, secuencias de retorno=Verdadero)	66,67%	0,68	0,76
	Gestos con las manos	Abandono: (0,2) LSTM: (100 unidades, secuencias de retorno=Verdadero)	58,33%	0,56	0,70
	Movimiento de cabeza + Seguimiento ocular + Mano Gestos	Abandono: (0,2) LSTM: (100 unidades)	62,50%	0,62	0,75
	Movimiento de cabeza + Seguimiento ocular + Mano Gestos + Frecuencia cardíaca	Abandono: (0,2) Denso: (50 unidades, activación Relu) Denso: (3 unidades, activación Softmax)	70,83%	0,71	0,83
Red neuronal recurrente	Movimiento de la cabeza	Entrada: (tamaño de la ventana, 6, 9, 21 o 22)	45,83%	0,43	0,64
	Seguimiento ocular	SimpleRNN: (128 unidades):	41,67%	0,44	0,62
	Gestos con las manos	Abandono: (0,5) SimpleRNN: (64 unidades)	33%	0,29	0,53
	Movimiento de cabeza + Seguimiento ocular + Mano Gestos	Abandono: (0,5) Denso: (32 unidades, activación Relu)	66,7	0,68	0,82
	Movimiento de cabeza + Seguimiento ocular + Mano Gestos + Frecuencia cardíaca	Denso: (3 unidades, activación Softmax)	62,50%	0,59	0,82
SVM	Movimiento de la cabeza	C: 1	54,17%	0,54	0,66
	Seguimiento ocular	peso de clase: equilibrado	50,00%	0,51	0,52
	Gestos con las manos	grado: 2	50,00%	0,49	0,68
	Movimiento de cabeza + Seguimiento ocular + Mano Gestos	núcleo: poli	54,17%	0,53	0,66
	Movimiento de cabeza + Seguimiento ocular + Mano Gestos + Frecuencia cardíaca	encogimiento: verdadero tol: 0,0001	54,17%	0,53	0,63
Regresión logística	Movimiento de la cabeza	C: 1,	37,50%	0,37	0,68
	Seguimiento ocular	peso_de_clase: equilibrado,	45,83%	0,46	0,67
	Gestos con las manos	max_iter: 100	37,50%	0,37	0,65
	Movimiento de cabeza + Seguimiento ocular + Mano Gestos	penalización: l1	58,33%	0,58	0,70
	Movimiento de cabeza + Seguimiento ocular + Mano Gestos + Frecuencia cardíaca	solucionador: saga tol: 0,001	58,33%	0,58	0,75
Bosque aleatorio	Movimiento de la cabeza	Bootstrap: Falso	70,83%	0,73	0,86
	Seguimiento ocular	profundidad_máxima: 10	54,17%	0,55	0,80
	Gestos con las manos	max_features: log2	62,50%	0,60	0,84
	Movimiento de cabeza + Seguimiento ocular + Mano Gestos	min_samples_leaf: 1	70,83%	0,72	0,88
	Movimiento de cabeza + Seguimiento ocular + Mano Gestos + Frecuencia cardíaca	min_samples_split: 2 n_estimadores: 200	70,83%	0,72	0,88

Tabla 3. Comparación del rendimiento de diferentes combinaciones de datos de sensores. Los valores significativos están en [negrita].

.....




Figura 7. Tiempos de finalización de las tareas para todos los experimentos.

El tiempo promedio de finalización de la tarea en el entorno de carga cognitiva A fue de 65,33 s. En el entorno de carga cognitiva B, el tiempo de finalización fue de 50,13 s, mientras que el grupo de control C tuvo un tiempo promedio de finalización de 43,83 s. El tiempo promedio de finalización en el entorno de alta interferencia fue un 49 % mayor que en el entorno de baja interferencia.

Los resultados del análisis de varianza (ANOVA) indicaron que los tres entornos de carga cognitiva afectaron significativamente el tiempo de finalización de la tarea ($F=6,724$, $p=0,002<0,01$, eta parcial al cuadrado=0,103). Se observó que el tiempo de finalización de la tarea en el entorno con menor ruido (grupo de control C) fue significativamente más rápido que en los entornos A y B. Este resultado confirma que los entornos de trabajo excesivamente ruidosos prolongan significativamente el tiempo de ejecución de las tareas de resonancia magnética.

Esta conclusión es consistente con los resultados del cuestionario NASA-TLX en este estudio, donde una mayor interferencia se correlacionó con un menor rendimiento y tiempos de finalización de tareas más prolongados. Además, esta conclusión coincide con hallazgos de investigaciones relacionadas en entornos que no son de realidad mixta,64 lo que valida aún más el impacto de los entornos de carga en el tiempo de finalización de las tareas.

Red de clasificación de carga cognitiva basada en transformador mejorado

El entorno de entrenamiento y prueba para el algoritmo de clasificación incluye Windows 10, Anaconda y Python 3.9, con configuraciones de hardware de i9 13900KF y RTX 4090 (24G). Utilizamos CUDA 11, TensorFlow-GPU y el marco de aprendizaje profundo Keras para acelerar el proceso de entrenamiento.

Debido a las variaciones en la duración total de las tareas experimentales entre los participantes, los datos de los sensores se registraron a una frecuencia de muestreo de 30 Hz, lo que resultó en datos de series temporales que oscilaban entre 1000 y 2500 filas por sujeto. Para estandarizar la entrada para el entrenamiento del modelo, todas las secuencias se normalizaron a una longitud fija de 2500 filas. Para las secuencias más cortas de 2500 filas, se completó el conjunto de datos mediante repetición para garantizar la consistencia. Los datos estandarizados se segmentaron en ventanas de longitud fija y sin solapamiento de 500 filas cada una, extraídas secuencialmente desde el principio hasta el final de la secuencia. Cada ventana se trató como una muestra de entrada independiente. La etiqueta de carga cognitiva para cada ventana se determinó en función de la etiqueta que aparecía con mayor frecuencia dentro de esa ventana. El conjunto de datos preprocesado resultante se utilizó posteriormente como entrada para el entrenamiento del modelo.

Dado que los flujos de datos de los sensores recopilados presentan diferentes formatos de datos, la normalización de estos diferentes flujos de datos de sensores es esencial para que el algoritmo de clasificación extraiga información significativa. Inicialmente, convertimos las etiquetas de los tres entornos de carga cognitiva en números enteros. A continuación, estandarizamos las columnas de datos para cada sensor. Para cada característica (columna), calculamos la media y la desviación estándar en todas las muestras. Luego, los datos se estandarizaron utilizando estos valores calculados de media y desviación estándar. El proceso de cálculo específico es el siguiente: suponiendo que la matriz de datos de características recopiladas por el sensor es X , donde X contiene n muestras y j

características. El valor medio para cada columna de características se calcula de la siguiente manera:

$$\mu_j = \frac{1}{n} \sum_{i=1}^n x_{ij} \quad (1)$$

donde X_{ij} representa el valor de la j -ésima característica en la i -ésima muestra. La desviación estándar para cada característica se calcula de la siguiente manera:

$$\sigma_j = \sqrt{\frac{1}{n} \sum_{i=1}^n (X_{ij} - \mu_j)^2} \quad (2)$$

Finalmente, utilizando la media calculada μ_j y la desviación estándar σ_j para obtener los resultados de datos de entrada estandarizados X'_{ij}

$$X'_{ij} = \frac{X_{ij} - \mu_j}{\sigma_j} \quad (3)$$

Al diseñar una red de aprendizaje profundo basada en la estructura Transformer para la clasificación de carga cognitiva, hicimos varias modificaciones para adaptarla a la tarea de clasificación específica. Dado que no estamos trabajando con información textual, simplificamos la capa de incrustación de entrada y el módulo de codificación posicional. Esto permitió que el modelo manejara eficazmente datos de series temporales de sensores de diferentes entornos de carga cognitiva y se centrara en las relaciones entre los puntos de datos. En nuestra red, la entrada al mecanismo de atención es $Q=K=V=X_{input}$, donde el número de cabezas es H y la dimensión de cada cabeza es d_k . Las puntuaciones de atención se calculan de la siguiente manera:

$$\text{Atención}(Q, K, V) = \text{softmax} \left(\frac{QK^T}{\sqrt{d_k}} \right) V \quad (4)$$

El mecanismo de atención multi-cabeza calcula las puntuaciones de atención mapeando la entrada en H subespacios diferentes. La matriz de pesos de salida de atención se denota como W_o .

$$\text{MultiHead}(Q, K, V) = \text{Concat}(\text{head}_1, \dots, \text{head}_h) W_o \quad (5)$$

Para estabilizar el proceso de entrenamiento, empleamos conexiones residuales y normalización de capas:

$$Z_1 = \text{LayerNorm}(X_{input} + \text{MultiHead}(Q, K, V)) \quad (6)$$

La red neuronal de alimentación directa consta de dos capas totalmente conectadas, cada una seguida de una función de activación ReLU:

$$\text{FFN}_1(Z_1) = \text{ReLU}(Z_1 W_1 + b_1) \quad (7)$$

Después de la red de alimentación directa, volvemos a utilizar conexiones residuales y normalización de capas:

$$\text{FFN}_2(Z_2) = Z_2 W_2 + b_2 \quad (8)$$

$$Z_2 = \text{Norma de capa}(Z_1 + \text{FFN}_1(\text{FFN}_1(Z_1))) \quad (9)$$

Antes de generar el resultado final, aplicamos un agrupamiento promedio global a los datos de la secuencia para reducir su dimensionalidad:

$$Z_{pool} = \frac{1}{w} \sum_{i=1}^w Z_{output,i} \quad (10)$$

La salida de la capa de agrupación promedio global se introduce en una capa totalmente conectada:

$$Z_{dense1} = \text{ReLU}(Z_{pool} W_{dense1} + b_{dense1}) \quad (11)$$

Esta capa produce los resultados de clasificación de la carga cognitiva.

$$y_{load} = \text{softmax}(Z_{drop1} W_{dense2} + b_{dense2}) \quad (12)$$

Para evitar el sobreajuste, añadimos múltiples capas de abandono con una tasa de abandono de 0.5. La estructura general de la red del modelo de clasificación Transformer-cl se ilustra en la figura 8.

Para evaluar el rendimiento de clasificación del modelo, introducimos la precisión, la puntuación F1 y el AUC como métricas de evaluación clave. La precisión sirve como medida fundamental de la corrección general de la clasificación del modelo.

La matriz de confusión para la clasificación de la carga cognitiva se presenta de la siguiente manera:

$$\begin{matrix} & \text{H} \\ \text{FPM} & \text{TPM} & \text{FP}' \\ \text{[TPL } & \text{FPH} & \text{FR}' \\ & \text{METRO} & \text{TPL} \end{matrix} \quad (13)$$

Para los tres niveles de carga cognitiva (alto, medio y bajo), las instancias clasificadas correctamente se denominan TPH. (Verdadero positivo para carga alta), TPM (Verdadero positivo para carga media) y TPL (Verdadero positivo para carga baja). Dado que el número total de instancias clasificadas es N_{total} , la precisión de clasificación del modelo se puede calcular utilizando la siguiente fórmula:




Figura 8. Red de clasificación de carga cognitiva basada en Transformer-CL mejorado.

$$\text{Precisión} = \frac{\text{TPH} + \text{TPM} + \text{TPL}}{\text{Ntotal}} \times 100\% \quad (14)$$

En segundo lugar, se introduce la puntuación F1 como una métrica clave de rendimiento, que se deriva de la precisión y la exhaustividad. Se calcula utilizando la siguiente fórmula:

$$\text{Precisión} = \frac{\text{TP}}{\text{TP} + \text{FP}} \quad (15)$$

$$\text{Recordatorio} = \frac{\text{TP}}{\text{TP} + \text{FN}} \quad (16)$$

$$\text{F1} = \frac{2 \times \text{Precisión} \times \text{Recuperación}}{\text{Precisión} + \text{Recuperación}} \quad (17)$$

Para mitigar el impacto del desequilibrio de clases, adoptamos la puntuación F1 ponderada, que tiene en cuenta la proporción de cada clase en el conjunto de prueba. La puntuación F1 ponderada se calcula de la siguiente manera:

$$\text{F1W ocho} = \sum_{i=1}^3 \text{con} \times \text{F1i} \quad (18)$$

Donde w_i representa la proporción de la clase i en el conjunto de prueba, y F1ide denota la puntuación F1 de la clase.

El área bajo la curva (AUC) representa el área bajo la curva de características operativas del receptor (ROC), que sirve como métrica clave para evaluar la capacidad de clasificación del modelo. El AUC se calcula utilizando la siguiente fórmula:

$$\text{AUC} = \frac{1}{N + N^-} \sum_{x^+} \sum_{x^-} 1(f(x^+) > f(x^-)) \quad (19)$$

donde N^+ y N^- denotan el número de muestras positivas y negativas, respectivamente. La función $f(x)$ representa la puntuación predicha para una muestra dada, y $1(f(x^+) > f(x^-))$ es una función indicadora que es igual a 1 si la puntuación predicha para una muestra positiva es mayor que la de una muestra negativa, y 0 en caso contrario. Para la clasificación multiclase, se emplea la estrategia uno contra el resto (OvR) para calcular el AUC. El valor final del AUC se obtiene promediando las puntuaciones AUC para cada clase, donde AUC_i representa la puntuación AUC para la clase i .

$$AUC = \frac{1}{3} \sum_{i=1}^3 AUC_i \quad (20)$$

Los parámetros de entrenamiento específicos son los siguientes: el tamaño del lote se establece en 16, la época de entrenamiento en 1000 y se utiliza una función de devolución de llamada para obtener el modelo con el mejor rendimiento de clasificación. La proporción del conjunto de validación se establece en el 20 % del conjunto de datos. Mediante múltiples experimentos comparativos, evaluamos el rendimiento de nuestro método frente a los modelos RNN, LSTM y BiLSTM, así como frente a modelos de clasificación tradicionales como SVM, regresión logística y bosques aleatorios. La red Transformer-CL mejorada demuestra un rendimiento de clasificación prometedor, alcanzando una precisión máxima del 95,83 %, una puntuación F1 de 0,96 y un AUC de 0,99, lo que destaca su eficacia en la clasificación de la carga cognitiva. La comparación detallada del rendimiento se presenta en la Tabla 3. Esta evaluación exhaustiva demuestra el potencial de las arquitecturas basadas en Transformer en aplicaciones de clasificación de la carga cognitiva.

Para comprender las interdependencias dentro de los datos del sensor, extrajimos los pesos de atención del modelo Transformer-CL entrenado y realizamos un análisis detallado del mecanismo de atención del modelo. Este análisis nos llevó a crear mapas de calor que representan los pesos de atención en las dimensiones espaciales y temporales.

Para comprender las interdependencias dentro de los datos del sensor, extrajimos los pesos de atención del modelo Transformer-CL entrenado y realizamos un análisis detallado del mecanismo de atención del modelo. Este análisis nos llevó a crear mapas de calor que representan los pesos de atención en las dimensiones espaciales y temporales.

En la figura 9 se muestra el tiempo de atención promedio y la visualización de los pesos para los mecanismos espaciales y mecánicos. A partir de esta visualización de pesos, observamos que los pesos asociados con los datos de postura de la cabeza y los datos de postura de la mano derecha son relativamente mayores, lo que sugiere que la red de clasificación ha identificado más información relacionada con la carga cognitiva en estos datos.

Sistema prototipo de alerta de alta carga cognitiva en un entorno de resonancia magnética.

En entornos de trabajo con interfaz hombre-máquina de resonancia magnética (IHMRM), la exposición prolongada a condiciones de alta carga cognitiva puede generar problemas de seguridad. Detectar a los trabajadores sometidos a una carga cognitiva elevada y sostenida resulta complejo, ya que normalmente requiere el uso de equipos como gorros de EEG, rastreadores oculares y sensores fisiológicos externos. En un entorno de gemelo digital de RM, los trabajadores deben usar un casco de realidad virtual de RM (HMD) durante sus tareas. Al integrar los sensores en el HMD para capturar y clasificar la carga cognitiva en tiempo real, resulta más sencillo identificar los niveles de carga cognitiva de los trabajadores en el lugar de trabajo.

Desarrollamos un prototipo de sistema de alerta de alta carga para MR basado en Unity y PyQt. El sistema funciona de la siguiente manera: recibe y registra continuamente flujos de datos de sensores del MR-HMD. Cuando los datos registrados alcanzan las 500 filas (aproximadamente 16,6 s a una frecuencia de muestreo de 30 Hz), el sistema guarda automáticamente los datos y los importa a la red de clasificación de carga cognitiva para identificar el estado de carga de trabajo actual del participante. Si un trabajador permanece en un estado de alta carga cognitiva durante cinco períodos de detección consecutivos, se activa el sistema de alerta. Aparece una ventana emergente de alerta, que le pide al trabajador que elija entre tomar un descanso o solicitar ayuda. Si el trabajador opta por un descanso, el sistema silencia temporalmente el sonido y la pantalla de la alarma, le indica al trabajador que se quite el MR-HMD, descanse y luego reanude el trabajo. Cuando se hace clic en el botón "Solicitar ayuda", el MR-HMD envía un comando al host de monitoreo del sistema. El personal directivo al final del programa recibirá alertas relevantes, como se muestra en la Fig. 10. Esto permite a la dirección identificar rápidamente a los trabajadores que experimentan situaciones prolongadas de alta carga y




Figura 9. (a) Visualización del peso promedio del mecanismo de atención temporal. (b) Visualización del peso promedio del mecanismo de atención espacial.




Figura 10. Prototipo de sistema de control de carga cognitiva en fábrica.

Se envía personal técnico para que les ayude a resolver los problemas relacionados. Este enfoque proactivo ayuda a mitigar la ansiedad, los errores y los problemas de seguridad que pueden surgir de la exposición prolongada a entornos con alta carga cognitiva.

Discusión y limitaciones

En el contexto de futuros entornos de interacción persona-ordenador (HCI) basados en realidad mixta (RM), exploramos el uso de los sensores integrados en los dispositivos de RM-HMD para evaluar la carga cognitiva de los trabajadores, aprovechando la red Transformer-CL para la clasificación de dicha carga. Los resultados experimentales indican que los datos de los sensores de los dispositivos de RM-HMD contienen información latente relacionada con la carga cognitiva de los participantes, la cual refleja la interferencia del entorno de carga en el desempeño de la tarea y puede servir como base para la clasificación de la carga cognitiva.

Evaluamos experimentalmente el impacto del uso de datos de sensores unimodales y multimodales en el rendimiento de la clasificación de la carga cognitiva. Los resultados indican que la combinación de "Movimiento de cabeza + Seguimiento ocular + Gestos de la mano" como un conjunto de datos trimodal logró el mejor rendimiento en la mayoría de los modelos de clasificación. El modelo Transformer-CL mostró el mayor rendimiento en los datos trimodales, alcanzando una precisión del 95,83 %, lo que resalta las ventajas del mecanismo de autoatención para capturar relaciones temporales y características clave. Cabe destacar que la introducción de datos de frecuencia cardíaca provocó una disminución en el rendimiento de clasificación de los modelos primarios. Por ejemplo, la precisión del modelo Transformer-CL cayó del 95,83 % al 83,33 %. Este fenómeno sugiere que, si bien la frecuencia cardíaca es una señal fisiológica importante, su relevancia para la carga cognitiva puede ser menor en ciertas tareas.

El modelo LSTM mostró un rendimiento relativamente bajo en el conjunto de datos unimodal, con una precisión de solo el 62,50 %, y no mejoró significativamente su rendimiento en los datos multimodales, lo que indica una capacidad limitada para modelar dependencias temporales. En contraste, el modelo BiLSTM mejoró su capacidad de modelado temporal gracias a su estructura bidireccional, capturando dependencias tanto hacia adelante como hacia atrás.

Su precisión en el conjunto de datos trimodal aumentó al 80,56 %, con una puntuación F1 de 0,81 y un AUC de 0,89, superando significativamente a la LSTM. Sin embargo, la diferencia entre BiLSTM y Transformer-CL siguió siendo considerable, ya que Transformer-CL logró una precisión un 15,27 % mayor en el mismo conjunto de datos.

El modelo RNN solo alcanzó una precisión del 66,7 % en el conjunto de datos trimodal, lo que evidencia sus limitaciones para manejar dependencias temporales complejas. La estructura simple de la RNN la hizo menos eficaz para capturar dependencias de largo alcance y características intermodales en datos multimodales, lo que limitó su rendimiento en la clasificación de la carga cognitiva.

Los modelos tradicionales de aprendizaje automático, como SVM y Regresión Logística, mostraron un rendimiento de clasificación significativamente menor en datos multimodales en comparación con los modelos de aprendizaje profundo. En particular, el SVM, al usar un núcleo polinomial (grado=2), logró una precisión de solo 54,17% en el conjunto de datos trimodal, y el AUC no mejoró significativamente, lo que sugiere su capacidad limitada para ajustarse a datos de características espaciotemporales de alta dimensión. El rendimiento de la Regresión Logística fue igualmente limitado, con una precisión máxima de 58,33% en el conjunto de datos trimodal. Entre los métodos tradicionales de aprendizaje automático, Random Forest tuvo un rendimiento relativamente bueno.

Alcanzó una precisión del 70,83 % en los datos trimodales, demostrando su ventaja en el manejo de datos estructurados. Sin embargo, su rendimiento aún se situó por debajo del de los modelos de aprendizaje profundo, especialmente al enfrentarse a datos temporales complejos y a la fusión de características multimodales.

En resumen, el modelo Transformer-CL demostró un rendimiento excepcional con datos multimodales, confirmando el potencial de las arquitecturas Transformer basadas en el mecanismo de autoatención para la clasificación de la carga cognitiva. La integración de datos multimodales mejoró significativamente el rendimiento de la clasificación, especialmente la combinación de datos de movimiento de cabeza, seguimiento ocular y gestos de la mano, que capturó eficazmente información multidimensional relacionada con la carga cognitiva. Los modelos tradicionales de aprendizaje automático tuvieron un rendimiento subóptimo en tareas de clasificación de carga cognitiva en comparación con los modelos de aprendizaje profundo, particularmente al enfrentarse a datos temporales complejos y la fusión de características multimodales. Los modelos de aprendizaje profundo exhibieron capacidades de clasificación superiores en estos contextos. Nuestros hallazgos proporcionan tanto apoyo teórico como referencias metodológicas para futuras investigaciones de clasificación multimodal en escenarios análogos.

Sin embargo, este estudio presenta varias limitaciones. Por ejemplo, si bien el modelo Transformer-CL alcanzó una precisión de clasificación de carga cognitiva del 95,83 %, es importante destacar que este resultado se obtuvo en condiciones experimentales controladas con un tamaño de muestra limitado. Además, el número total de muestras de entrenamiento recopiladas en el entorno experimental fue de 480, lo cual es relativamente pequeño. Los participantes, con una edad promedio de 25,1 años ($DE=2,14$) y experiencia previa en el manejo de máquinas CNC, pudieron familiarizarse con los procesos de la maquinaria con mayor rapidez durante el experimento. No obstante, en entornos de fábrica reales, las diferentes edades y conocimientos previos de los trabajadores, así como las diferencias individuales entre los participantes, podrían influir en los resultados. Asimismo, debido a las limitaciones del presente estudio, simulamos la interferencia de ruido de un entorno de fábrica real utilizando grabaciones de sonidos de fábrica, alarmas e interfaces de alarma para evitar riesgos de seguridad durante los experimentos en fábricas reales. Sin embargo, el ruido de fondo simulado puede diferir de la interferencia de ruido real en un entorno de fábrica real. Los distintos tipos de fábricas y las diversas tareas laborales también pueden presentar diferentes entornos de carga cognitiva. Por lo tanto, la generalización del modelo a través de diferentes entornos de fábrica, tipos de tareas y grupos de usuarios requiere una mayor validación mediante estudios futuros.

Con base en los resultados de este estudio, recomendamos controlar estratégicamente los elementos del entorno laboral que tienden a generar carga cognitiva. Por ejemplo, los futuros cascos de realidad mixta para uso industrial deberían integrar funciones de cancelación de ruido para mitigar el ruido ambiental de la maquinaria en entornos de fábrica. Además, es aconsejable controlar la cantidad de interfaces de alarma en un mismo entorno de trabajo, posiblemente apilando las ventanas de alerta según su nivel de importancia para la visualización de la información. Estas medidas ayudarán a reducir la carga cognitiva en entornos de fábrica complejos, salvaguardando así el bienestar psicológico de los trabajadores y la seguridad operativa.

En la implementación práctica del sistema de evaluación de la carga cognitiva, aún existen posibles obstáculos. Por ejemplo, si bien los dispositivos MR-HMD pueden mejorar la eficiencia de las tareas de mantenimiento, el alto costo de adquisición y capacitación para su uso (como HoloLens y Vision Pro, con un precio aproximado de \$3,500) limita su aplicación generalizada en la producción industrial. Además, su duración de batería relativamente corta (2-3 h) y su peso (aproximadamente 560-650 g) representan dificultades durante la capacitación del usuario. Asimismo, aunque algunos MR-HMD están disponibles en versiones industriales, su desempeño en condiciones extremas, como altas temperaturas, alta salinidad y alta humedad, aún requiere mayor investigación. Por otra parte, debido a la limitada capacidad de procesamiento de HoloLens 2, no realizamos las tareas de clasificación directamente en el procesador del MR-HMD, sino que transmitimos los datos a una computadora terminal para su clasificación. En fábricas con entornos de red y electromagnéticos complejos, esta transmisión de datos puede generar ciertas demoras en el procesamiento de datos.

Conclusión

En este estudio, examinamos el impacto de los factores de interferencia cognitiva en entornos de RM sobre las tareas de interacción persona-ordenador (HCI). Diseñamos un experimento controlado con tres niveles diferentes de interferencia de carga en tareas de HCI en RM. Mediante sensores integrados en un casco de realidad virtual de RM (MR-HMD), recopilamos datos fisiológicos de los participantes que operaban máquinas CNC en entornos de RM, creando un conjunto de datos multimodales de carga cognitiva. Evaluamos la carga cognitiva utilizando el cuestionario NASA-TLX durante los experimentos. Los resultados indican que la interferencia de carga afecta significativamente las tareas de HCI en RM; en condiciones de alta interferencia, los tiempos promedio de finalización se extendieron un 49 % en comparación con el grupo de control. Además, las condiciones de alta interferencia aumentaron la ansiedad y la frustración, lo que provocó una disminución en el rendimiento de la tarea entre los operadores.

Para clasificar la carga cognitiva, utilizamos una red Transformer-CL mejorada, logrando una precisión del 95,83 %. Los resultados experimentales validaron nuestra hipótesis de que los datos de los sensores del MR-HMD contienen información oculta relacionada con la carga cognitiva, la cual refleja la interferencia del entorno de carga en el desempeño de las tareas de los participantes. Además, diseñamos un prototipo de sistema de alerta de carga cognitiva para fábricas con gemelos digitales de RM, con el fin de ayudar a los trabajadores en entornos de RM con alta carga cognitiva y, por consiguiente, reducir los riesgos de seguridad en dichos entornos.

En futuras investigaciones, nuestro objetivo es integrar flujos de datos de sensores adicionales en los sistemas de clasificación de carga cognitiva, como la variabilidad de la frecuencia cardíaca (VFC), secuencias de vídeo y datos espaciales. Además, exploraremos el impacto de los comportamientos personalizados de los trabajadores en la detección de la carga cognitiva y evaluaremos las diferencias de rendimiento entre diversos dispositivos de resonancia magnética. Mediante estos esfuerzos, prevemos mejorar aún más la precisión del reconocimiento de escenarios de carga cognitiva y la clasificación de la carga, lo que en última instancia proporcionará un mejor apoyo y protección a los trabajadores en entornos operativos complejos.

Disponibilidad de datos

Los datos se proporcionan en el manuscrito o en los archivos de información complementaria.

Recibido: 8 de enero de 2025; Aceptado: 15 de abril de 2025

Published online: 21 April 2025

Referencias

1. Zhang, C. et al. Hacia una fabricación inteligente centrada en el ser humano de nueva generación en la industria 5.0: una revisión sistemática. *Adv. Eng. Inf.* 57, 102121 (2023).
2. Nickel, P. et al. Requisitos de diseño de interacción humano-sistema para mejorar la seguridad de la maquinaria y los sistemas. *Adv. Saf. Manage. Hum. FACTORES*. 969, 3–13 (2020).
3. Chinniah, Y., Aucourt, B. y Bourbonniere, R. Seguridad de la maquinaria industrial en condiciones de riesgo reducido. *Saf. Sci.* 93, 152–161 (2017).
4. Benson, C., Obasi, IC, Akinwande, DV e Ile, C. El impacto de las intervenciones en la salud, la seguridad y el medio ambiente en el proceso industria. *Heliyon* 10, e23604 (2024).
5. Zhou, H., Wang, D., Yu, Y. y Zhang, Z. Avances en la investigación de la tecnología de interacción humano-computadora basada en el reconocimiento de gestos. *Electronics* 12, 2805 (2023).
6. Zhang, S., He, C. y Ji, Z. Estudio sobre el diseño de la interfaz hombre-máquina de la maquinaria de construcción. En *Advances in Intelligent Systems and Computing* 78–85 (2019).
7. Arana-De, LCN, De la Riva-Rodríguez, J., Maldonado-Macias, AA y Saenz-Zamarron, D. Análisis cognitivos para el diseño de interfaces mediante tareas duales N-Back para la evaluación de la carga de trabajo mental (MWL). *Int. J. Environ. Res. Public. Health* 20, 145 (2023).
8. Koelewijn, T., Shinn-Cunningham, BG, Zekveld, AA y Kramer, SE La respuesta pupilar es sensible a la atención dividida durante Procesamiento del habla. *Hear. Res.* 312, 114–120 (2014).
9. Ke, J., Liao, P., Li, J. y Luo, X. Efecto de la carga de información y el estilo cognitivo en la carga cognitiva de los paneles visualizados para actividades relacionadas con la construcción. *Autom. Constr.* 154, 105029 (2023).
10. Chen, YC, Chang, YS y Chuang, MJ La aplicación de realidad virtual influye en los componentes de la creatividad mediados por la carga cognitiva y en el rendimiento creativo en el diseño de ingeniería. *J. Comput. Assist. Learn.* 38, 6–18 (2022).
11. Atici-Ulus, H., Ikiz, YD, Taskapilioglu, O. y Gunduz, T. Efectos de las gafas de realidad aumentada en la carga cognitiva del ensamblaje. operadores en la industria automotriz. *Int. J. Comput. Integr. Manuf.* 34, 487–499 (2021).
12. Loup-Escande, E. et al. Contribuciones de la realidad mixta en una tarea de aprendizaje de caligrafía: efectos de la retroalimentación visual suplementaria y la experiencia en la carga cognitiva, la experiencia del usuario y el rendimiento gestual. *Comput. Hum. Behav.* 75, 42–49 (2017).
13. Zhu, Y. et al. Una plataforma interactiva de realidad mixta para la educación basada en la indagación. En *2021 IEEE 7th International Conference on Realidad Virtual (ICVR)* 324–331 (Foshan, 2021).
14. Eom, S. et al. Precisión de la colocación rutinaria de drenaje ventricular externo tras una craneostomía con taladro helicoidal guiada por realidad mixta. *Neurocirugía. Enfoque* 56, E11 (2024).
15. Graf, M. y Barthet, M. Reducción de errores de detección en un instrumento musical de realidad mixta. En *VRST '23 Nueva York* (2023).
16. Buyruk, Y. y Cagdas, G. Diseño paramétrico interactivo y fabricación robótica en un entorno de realidad mixta. *Appl. Sci.* -Basel. 12, 12797 (2022).
17. Papadopoulos, T., Evangelidis, K., Evangelidis, G. y Kaskalis, TH Realidad mixta e internet de las cosas: uniendo lo virtual con lo real. *Adv. Eng. Softw.* 185, 103527 (2023).
18. James, S. y Eckert, GA. Estudio de viabilidad sobre una herramienta de visualización e interacción basada en realidad mixta para la mejora del rendimiento. de procesos de corte de metales. *Metales* 13, 286 (2023).
19. Dai, M. et al. Investigación sobre una plataforma de verificación de visualización holográfica para maquinaria de construcción basada en tecnología de realidad mixta. *Appl. Sci.* 13, 3692 (2023).
20. Vanneste, P. et al. Soporte cognitivo para operaciones de ensamblaje mediante realidad aumentada: un estudio exploratorio. *Int. J. Hum. -Comput Stud.* 143, 102480 (2020).
21. Kucuk, S., Kapakin, S. y Goktas, Y. Aprendizaje de anatomía mediante realidad aumentada móvil: efectos sobre el rendimiento y la carga cognitiva. *Anat. Sci. Educ.* 9, 411–421 (2016).
22. Cheng, K. Lectura de un libro de realidad aumentada: una exploración de la carga cognitiva, la motivación y las actitudes de los estudiantes. *Australas J. Tecnología Educativa* 33, 53–69 (2017).
23. Makransky, G., Terkildsen, TS y Mayer, RE. Agregar realidad virtual inmersiva a una simulación de laboratorio científico provoca una mayor presencia. pero menos aprendizaje. *Aprender. Instr.* 60, 225–236 (2019).
24. Fehrenbacher, DD y Djamasbi, S. Sistemas de información y demanda de tareas: un estudio exploratorio de pupilometría de sistemas computarizados Toma de decisiones. *Decis. Support Syst.* 97, 1–11 (2017).
25. Figueroa, AM y Juarez-Ramirez, R. El problema de la carga cognitiva en las GUI: hacia el establecimiento de la relación entre la carga cognitiva y nuestras funciones ejecutivas. En *2017 IEEE 41st Annual Computer Software And Applications Conference (COMPSAC)*, VOL 2 561–565 (2017).
26. Zhu, R., Ma, X. y You, X. El efecto de la carga de memoria de trabajo en la sordera por falta de atención durante la toma de decisiones aeronáuticas. *Appl. Ergon.* 113, 104099 (2023).
27. Sweller, J. Carga cognitiva durante la resolución de problemas: efectos en el aprendizaje. *Cogn. Sci.* 12, 257–285 (1988).
28. Kockord, R. y Bodensiek, O. Carga cognitiva durante el primer contacto con entornos de aprendizaje de realidad mixta. En *Mensch And Computer 2021 (MUC 21)* 260–264 (2021).
29. Amadori, PV, Fischer, T., Wang, R. y Demiris, Y. Predicción del rendimiento en tareas secundarias: una métrica directamente procesable para Detección de sobrecarga cognitiva. *IEEE Trans. Cogn. Dev. Syst.* 14, 1474–1485 (2022).
30. Arana-De Las Casas, NI, De la Riva-Rodríguez, J. & Maldonado-Macias, AA Sáenz-Zamarrón, D. Análisis cognitivos para el diseño de interfaces utilizando tareas duales N-Back para la evaluación de la carga de trabajo mental (MWL). *Int. J. Medio Ambiente. Res. Salud Pública.* 20, 1184 (2023).
31. Van der Heiden, RMA, Janssen, CP, Donker, SF y Kenemans, JL La influencia de la carga cognitiva en la susceptibilidad al audio. *Acta Psicológica. (Amst).* 205, 103058 (2020).
32. Van Dillen, LF, Heslenfeld, DJ y Koole, SL. Desactivando el cerebro emocional: un estudio de resonancia magnética funcional sobre los efectos de la carga cognitiva. Sobre el procesamiento de imágenes afectivas. *Neuroimage* 45, 1212–1219 (2009).
33. Stojmenova, K. y Sodnik, J. Validación del método de tarea de respuesta de detección auditiva para evaluar los efectos atencionales de la carga cognitiva. *Traffic Inj Prev.* 19, 495–500 (2018).
34. An, S. et al. Efectos de la preestimulación auditiva en el rendimiento de tareas cognitivas en un entorno ruidoso. *Appl. Sci.* 12, 5823 (2022).
35. Zhou, H., Molesworth, BRC, Burgess, M. y Hatfield, J. El efecto del ruido de banda ancha moderado en el rendimiento cognitivo: una revisión sistemática. *Cogn. Technol. Work.* 26, 1–36 (2024).
36. Smucny, J., Rojas, DC, Eichman, LC y Tregellas, JR Efectos neuronales de la distracción auditiva en la atención visual. *Brain Cogn.* 81, 263–270 (2013).
37. Hao, H. y Conway, A. El impacto de la distracción auditiva en la comprensión lectora: una investigación de diferencias individuales. *Mem. Cognit.* 50, 852–863 (2022).
38. Rudner, M. Capacidad cognitiva de reserva como índice del esfuerzo auditivo. *Ear Hear.* 37, 69S–76S (2016).
39. Jin, T. et al. El impacto del ruido ambiental en las capacidades cognitivas de los conductores: un estudio de caso sobre interfaces de interacción por voz en vehículos. *Aplica. Ergón.* 117, 104247 (2024).

40. Kazemi, R. et al. Desarrollo y validación de un índice de carga de trabajo para operadores de salas de control de procesos (PCRO-TLX). *Ergonomics* 66, 2121–2132 (2023).
41. Zak, Y., Parmet, Y. y Oron-Gilad, T. Técnica de evaluación subjetiva de la carga de trabajo (SWAT) en tiempo real: metodología asequible para evaluar continuamente la carga de trabajo de los operadores humanos. En 2020 IEEE International Conference On Systems, Man, And Cybernetics (SMC) 2687–2694 (2020).
42. Krehl, C. y Balfe, N. Análisis de la carga cognitiva en entornos de señalización ferroviaria. *Cogn. Technol. Work.* 16, 359–371 (2014).
43. Mansikka, H., Virtanen, K. y Harris, D. Comparación de la escala NASA-TLX, la escala Cooper-Harper modificada y el intervalo medio entre latidos. Intervalo como medida de la carga de trabajo mental del piloto durante tareas de vuelo simuladas. *Ergonomics* 62, 246–254 (2017).
44. Suzuki, Y., Wild, F. y Scanlon, E. Medición de la carga cognitiva en realidad aumentada con métodos fisiológicos: una revisión sistemática. *J. Comput. Assist. Learn.* 40, 375–393 (2024).
45. Ahmadi, M. et al. Medición de la carga cognitiva con sensores fisiológicos en realidad virtual durante la actividad física. En 29th Acm Simposio sobre software y tecnología de realidad virtual, VRST 2023 (2023).
46. van der Wel, P. y van Steenbergen, H. Dilatación pupilar como índice de esfuerzo en tareas de control cognitivo: una revisión. *Psychon. Bull. Rev.* 25, 2005–2015 (2018).
47. Cong, R., Tago, K. y Jin, Q. Medición y verificación de la carga cognitiva en presentaciones multimedia mediante un rastreador ocular. *Multimed. Tools Appl.* 81, 26821–26835 (2022).
48. Jercic, P., Sennersten, C. y Lindley, C. Modelado de la carga cognitiva y la activación fisiológica a través del diámetro pupilar y la frecuencia cardíaca. *Multimed. Tools Appl.* 79, 3145–3159 (2020).
49. Yoo, G., Kim, H. y Hong, S. Predicción de la carga cognitiva a partir de señales de electroencefalografía utilizando la red de memoria a corto y largo plazo. *Bioeng.-Basel* 10, 361 (2023).
50. Yedukondalu, J., Sharma, D. y Sharma, LD Detección de carga cognitiva por sujeto utilizando EEG tiempo-frecuencia y Bi-LSTM. *Arab. J. Ciencias. Ing.* (2011) 49, 4445–4457 (2024).
51. Kuanar, S., Athitsos, V., Pradhan, N., Mishra, A. y Rao, KR. Análisis cognitivo de la carga de memoria de trabajo a partir de EEG mediante una red neuronal recurrente profunda. En IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP) 2576–2580 (Calgary, 2018).
52. Yang, J., Yang, H., Wu, Z. y Wu, X. Evaluación de la carga cognitiva del controlador de tráfico aéreo basada en la red SCNN-TransE utilizando datos de voz. *Aerospace* 10, 584 (2023).
53. Saikia, MJ. El enfoque de aprendizaje automático de agrupamiento K-Means revela grupos de individuos homogéneos con activación cerebral, dinámica de tareas y rendimiento únicos utilizando fNIRS. *IEEE Trans. Neural Syst. Rehabil. Eng.* 31, 2535–2544 (2023).
54. Pal, R. Reducción de la carga cognitiva mediante realidad mixta y cognición externa. En IndiaHCI '21 152–155 (Evento virtual, 2021).
55. Wang, W., Hong, X., Dang, S., Xu, N. y Qu, J. Diseño de disposición espacial 3D de la pantalla de información de la cabina de mando holográfica en entornos mixtos. Entorno de realidad basado en HoloLens 2. *Brain Sci.* 12, 971 (2022).
56. Dibene, JC y Dunn, E. HoloLens 2 Sensor Streaming.: arXiv (2022).
57. Ahmed, SS y Gademoula, AM Monitoreo de ruido industrial mediante la técnica de mapeo de ruido: un estudio de caso en una fábrica de bloques de hormigón. *Int. J. Environ. Sci. Technol.* 19, 851–862 (2022).
58. Hao, H. y Conway, ARA El impacto de la distracción auditiva en la comprensión lectora: una investigación sobre diferencias individuales. *Memoria. Cognir.* 50, 852–863 (2022).
59. Rios, D. et al. Alarma multisensorial para mejorar la identificación de alarmas y disminuir la carga de trabajo: un estudio de viabilidad. *J. Clin. Monit. Comp.* 37, 1051–1059 (2023).
60. Hart, SG y Staveland, LE En Carga de trabajo mental humana, vol. 52 (eds. Hancock, PA y Meshkati, N.) 139–183 (North-Holland, 1988).
61. Bolton, ML, Biltekoff, E. y Humphrey, L. La falta de significado matemático del índice de carga de trabajo de la NASA: un nivel de medición análisis. *IEEE T Hum. -Mach Syst.* 53, 590–599 (2023).
62. Galy, E., Paxion, J. y Berthelon, C. La medición de la carga de trabajo mental con el NASA-TLX requiere examinar cada dimensión en lugar de basarse en la puntuación global: un ejemplo con la conducción. *Ergonomics* 61, 517–527 (2018).
63. Zhao, K. y Weiping, L. Estudio sobre los efectos del ruido en la carga de trabajo mental de Crew en el procesamiento de información. En MMESA 2018 393–399 (Singapur, 2019).
64. Haghighat, P. et al. Efectos de un asistente virtual inteligente en el rendimiento de las tareas de oficina y la carga de trabajo en un entorno ruidoso. *Appl. Ergon.* 109, 103969 (2023).

Contribuciones de los autores

Yukang Hou: Redacción – Borrador original, conceptualización, metodología, curación de datos, análisis formal, investigación, software, validación, visualización. Qingsheng Xie: Administración del proyecto, supervisión, validación.

Ning Zhang: Metodología, Redacción (revisión y edición), Visualización. Jian Lv (Autor correspondiente): Redacción (revisión y edición), Administración del proyecto, Supervisión, Obtención de financiación, Validación. Todos los autores revisaron el manuscrito.

Fondos

Este trabajo fue financiado por la Fundación Nacional de Ciencias Naturales de China (Subvención n.º 52065010) y los Proyectos de Ciencia y Tecnología de la provincia de Guizhou (Subvenciones n.º [2022]197, [2022]067, [2023]274).

Intereses contrapuestos

Los autores declaran no tener ningún conflicto de intereses.

Aprobación ética

Esta investigación ha recibido la aprobación ética del Comité de Revisión Ética (HMEE-GZU-2023-TO25) de la Universidad de Guizhou. Se obtuvo el consentimiento informado de todos los participantes. Confirmamos que toda la investigación se lleva a cabo de acuerdo con las directrices pertinentes de la Declaración de Helsinki de 1964 en lo que respecta a la participación de seres humanos.

Información adicional

Información complementaria La versión en línea contiene material complementario disponible en <https://doi.org/10.1038/s41598-025-98891-3>.

La correspondencia y las solicitudes de materiales deben dirigirse a JL.

La información sobre reimpresiones y permisos está disponible en www.nature.com/reprints.

Nota del editor: Springer Nature mantiene una postura neutral con respecto a las reivindicaciones jurisdiccionales en los mapas publicados y las afiliaciones institucionales.

Acceso abierto. Este artículo está bajo la licencia Creative Commons Atribución-NoComercial-SinDerivadas 4.0 Internacional, que permite cualquier uso no comercial, compartir, distribuir y reproducir en cualquier medio o formato, siempre que se dé el crédito correspondiente al autor o autores originales y a la fuente, se proporcione un enlace a la licencia Creative Commons y se indique si se ha modificado el material licenciado. Bajo esta licencia, no se tiene permiso para compartir material adaptado derivado de este artículo o partes del mismo. Las imágenes u otro material de terceros incluidos en este artículo están sujetos a la licencia Creative Commons del artículo, a menos que se indique lo contrario en la línea de crédito del material. Si el material no está incluido en la licencia Creative Commons del artículo y su uso previsto no está permitido por la normativa vigente o excede el uso permitido, deberá obtener el permiso directamente del titular de los derechos de autor. Para ver una copia de esta licencia, visite <http://creativecommons.org/licenses/by-nc-nd/4.0/>.

© El/los autor/es 2025